

MVP ENGENHARIA DE DADOS

Aluna: Bianca Gonçalves de Oliveira

Matrícula: 4052025002425

1. Contexto de Negócios e Perguntas

Este trabalho tem como objetivo construir um modelo de dados por meio de pipelines de ETL desenvolvidos em SQL e PySpark, seguindo a arquitetura em camadas Bronze, Silver e Gold. A camada Bronze concentra a ingestão dos dados brutos tal como recebidos da fonte; a camada Silver reúne os processos de tratamento, padronização e verificação da qualidade dos dados; e a camada Gold disponibiliza um conjunto de dados consolidado e pronto para consumo analítico, voltado a responder às perguntas de negócio definidas para o projeto.

O projeto foi orientado pelas seguintes perguntas analíticas, relacionadas aos gêneros cinematográficos e à sua evolução ao longo do tempo:

1. Qual é o ranking dos gêneros de filmes lançados em um determinado ano, considerando a média das avaliações recebidas?
2. Quais são os 10 filmes (ou combinações de ano e gênero, na granularidade da tabela final) com as maiores notas, e quais os respectivos anos de lançamento e gêneros?
3. Dado um gênero específico, quais são os anos com as melhores avaliações médias, entre as 50 melhores combinações?
4. Quais são os anos que concentram o maior número de votos registrados, independentemente do gênero?

A base utilizada é a disponibilizada publicamente pelo IMDb (Internet Movie Database), que reúne informações sobre filmes, séries e documentários. Do conjunto completo de arquivos oferecidos pelo IMDb, foram importadas duas tabelas para este projeto: uma com dados descritivos dos títulos e outra com as métricas de avaliação atribuídas pelos usuários. Cada arquivo é distribuído em formato TSV (valores separados por tabulação), compactado em gzip, codificado em UTF-8, com cabeçalho na primeira linha e o marcador '\N' para indicar valores ausentes ou nulos.

Tabela 1 – title.basics.tsv.gz

Coluna	Tipo	Descrição
tconst	string	Identificador alfanumérico único do título.
titleType	string	Tipo/formato do título (ex.: movie, short, tvMovie, tvSeries).
primaryTitle	string	Título principal, usado em materiais promocionais no lançamento.
originalTitle	string	Título original, no idioma de origem.

Coluna	Tipo	Descrição
isAdult	boolean	Indicador de conteúdo adulto (0/1). Removida da análise.
startYear	YYYY	Ano de lançamento (ou de início, no caso de séries).
endYear	YYYY	Ano de encerramento, aplicável apenas a séries.
runtimeMinutes	integer	Duração do título, em minutos.
genres	string	Até três gêneros associados ao título, separados por vírgula.

Tabela 2 – title.ratings.tsv.gz

Coluna	Tipo	Descrição
tconst	string	Identificador alfanumérico único do título (chave de junção com title.basics).
averageRating	double	Nota média ponderada atribuída pelos usuários.
NumVotes	integer	Número de votos recebidos pelo título.

2. Carga dos Dados

A carga dos dados foi realizada em um notebook Databricks, utilizando uma SparkSession já provisionada pelo ambiente. Antes da ingestão, o banco de dados da camada Bronze foi removido (caso já existisse) e recriado, garantindo um ambiente limpo e evitando conflitos com tabelas homônimas de execuções anteriores.

```
from pyspark.sql import SparkSession

spark = SparkSession.builder.getOrCreate()

spark.sql("DROP DATABASE IF EXISTS bronze CASCADE")

spark.sql("CREATE DATABASE bronze")
```

Os dois arquivos TSV compactados (title.basics.tsv.gz e title.ratings.tsv.gz), previamente enviados ao workspace do Databricks, foram lidos com spark.read, configurando o separador de tabulação, a descompactação gzip, o cabeçalho como nome das colunas e o marcador '\N' como valor nulo. Durante a leitura de title.basics, a coluna isAdult apresentou erro em sua criação e foi descartada diretamente no carregamento, já que essa informação não seria utilizada para responder às perguntas da análise.

```
title_basics_spark_df = (spark.read
    .option("header", True)
    .option("sep", "\t")
    .option("compression", "gzip")
    .option("nullValue", "\N")
    .csv("/Workspace/Users/oliveirabianca@id.uff.br/DbAcademy/title.basics.tsv.gz")
    .drop("isAdult"))

title_ratings_spark_df = (spark.read
    .option("header", True)
    .option("sep", "\t")
```

```
.option("compression", "gzip")  
.option("nullValue", "\\N")  
.csv("/Workspace/Users/oliveirabianca@id.uff.br/DbAcademy/title.ratings.tsv.gz"))
```

Para tornar a escrita das tabelas mais resiliente a quedas de cluster por inatividade, foi criada uma função auxiliar (run_with_retry) que reexecuta a operação de escrita uma vez, recriando a sessão Spark, caso o erro capturado seja do tipo INACTIVITY_TIMEOUT.

```
def run_with_retry(func, max_retries=1):  
    for attempt in range(max_retries + 1):  
        try:  
            return func()  
        except Exception as e:  
            if "INACTIVITY_TIMEOUT" in str(e) and attempt < max_retries:  
                global spark  
                spark = DatabricksSession.builder.getOrCreate()  
                continue  
            raise
```

Os DataFrames foram então persistidos como tabelas gerenciadas na camada Bronze:

```
run_with_retry(lambda:  
title_basics_spark_df.write.mode("overwrite").saveAsTable("bronze.title_basics"))  
  
run_with_retry(lambda:  
title_ratings_spark_df.write.mode("overwrite").saveAsTable("bronze.title_ratings"))
```

Após a carga, o conteúdo das tabelas foi inspecionado por meio de consultas SQL simples, confirmando o sucesso da ingestão. Essa inspeção também permitiu identificar, na coluna titleType, os valores distintos de tipo de título disponíveis; como o projeto está delimitado à análise de produções cinematográficas, apenas os tipos movie, tvShort, short e tvMovie foram mantidos nas etapas seguintes.

```
%sql  
SELECT * FROM bronze.title_basics LIMIT 20
```

Table

+

🔍

🔼

📄

🗑️

	⌕ tconst	⌕ titleType	⌕ primaryTitle	⌕ originalTitle
1	tt0000001	short	Carmencita	Carmencita
2	tt0000002	short	Le clown et ses chiens	Le clown et ses chiens
3	tt0000003	short	Poor Pierrot	Pauvre Pierrot
4	tt0000004	short	Un bon bock	Un bon bock
5	tt0000005	short	Blacksmith Scene	Blacksmith Scene
6	tt0000006	short	Chinese Opium Den	Chinese Opium Den
7	tt0000007	short	Corbett and Courtney Before the Kinetogra...	Corbett and Courtney Before the Kinetogra
8	tt0000008	short	Edison Kinetoscopic Record of a Sneeze	Edison Kinetoscopic Record of a Sneeze
9	tt0000009	movie	Miss Jerry	Miss Jerry
10	tt0000010	short	Leaving the Factory	La sortie de l'usine Lumière à Lyon
11	tt0000011	short	Acrobatic Potpourri	Akrobatisches Potpourri
12	tt0000012	short	The Arrival of a Train	L'arrivée d'un train à La Ciotat
13	tt0000013	short	The Photographical Congress Arrives in Lyon	Le Débarquement du congrès de photogra
14	tt0000014	short	The Waterer Watered	L'arroseur arrosé
15	tt0000015	short	Around a Cabin	Autour d'une cabine

⬇️

⌵

20 rows

2.295s runtime

Refreshed at 9/26/26, 3:58 PM (7h ago)

```
%sql
SELECT DISTINCT titleType FROM bronze.title_basics;
```

Table  

	 titleType
1	tvMiniSeries
2	tvPilot
3	short
4	movie
5	tvEpisode
6	tvSeries
7	videoGame
8	tvMovie
9	tvSpecial
10	video
11	tvShort

  11 rows | 1.584s runtime

```
%sql  
SELECT * FROM bronze.title_ratings LIMIT 20
```

Table

+

	A_C^B tconst	A_C^B averageRating	A_C^B numVotes
1	tt0000001	5.7	2231
2	tt0000002	5.4	326
3	tt0000003	6.4	2386
4	tt0000004	5.0	202
5	tt0000005	6.2	3097
6	tt0000006	5.1	225
7	tt0000007	5.3	962
8	tt0000008	5.4	2421
9	tt0000009	5.3	239
10	tt0000010	6.8	8446
11	tt0000011	5.2	467
12	tt0000012	7.4	14243
13	tt0000013	5.7	2168
14	tt0000014	7.1	6537
15	tt0000015	6.1	1357

↓

▼

20 rows

1.691s runtime

3. Modelagem e Catálogo de Dados

O modelo de dados segue a arquitetura em três camadas. Na camada Bronze, as tabelas espelham a estrutura bruta dos arquivos de origem (apenas com a remoção de isAdult). Na camada Silver, title.basics é reestruturada por meio de uma operação de explode sobre a coluna de gêneros, de modo que cada combinação título/gênero passe a ocupar uma linha própria; como consequência, o identificador tconst, antes único, deixa de ser chave primária dessa tabela. As tabelas title_ratings e title_basics da camada Silver são então unidas (JOIN) por tconst, originando a tabela silver.title_joined, que serve de base para a agregação final. Na camada Gold, os dados são agregados por ano e gênero,

dando origem à tabela `gold.genre_analysis`, que concentra a média das avaliações e o total de votos para cada combinação, já filtrada para os tipos de título de interesse.

bronze.title_basics

Coluna	Tipo	Descrição
tconst	string	Identificador único do título.
titleType	string	Tipo/formato do título.
primaryTitle	string	Título principal.
originalTitle	string	Título original.
startYear	string	Ano de lançamento (bruto, como texto).
endYear	string	Ano de encerramento (séries).
runtimeMinutes	string	Duração em minutos (bruto, como texto).
genres	string	Gêneros associados, separados por vírgula.

bronze.title_ratings

Coluna	Tipo	Descrição
tconst	string	Identificador único do título.
averageRating	string	Nota média (bruta, como texto).
numVotes	string	Número de votos (bruto, como texto).

silver.title_basics (após explode de genre e limpeza)

Coluna	Tipo	Descrição
tconst	string	Identificador do título (não único nesta tabela).
primaryTitle	string	Título principal, com nulos/vazios tratados como 'Unknown'.
titleType	string	Tipo/formato do título.
startYear	string	Ano de lançamento, sem nulos e sem anos futuros (>2025).
startYear_int	int	Ano de lançamento convertido para inteiro.
genre	string	Um único gênero por linha, resultante do explode de genres.

silver.title_ratings

Coluna	Tipo	Descrição
tconst	string	Identificador do título.
averageRating	string	Nota média, validada no intervalo de 0 a 10.
numVotes	string	Número de votos, validado como maior que zero.

silver.title_joined

Coluna	Tipo	Descrição
tconst	string	Identificador do título.
titleType	string	Tipo/formato do título.

primaryTitle	string	Título principal.
startYear	string	Ano de lançamento.
genre	string	Gênero do título (uma linha por gênero).
averageRating	string	Nota média.
numVotes	string	Número de votos.

gold.genre_analysis

Coluna	Tipo	Descrição
year	string	Ano de lançamento (originado de startYear).
genre	string	Gênero do título.
avgRating	double	Média das avaliações, arredondada em 3 casas decimais.
totalVotes	bigint	Soma do número de votos para o par ano/gênero.

4. Pipeline de Dados

Todo o pipeline de ETL foi implementado em um único notebook do Databricks, organizado sequencialmente em três blocos correspondentes às camadas Bronze, Silver e Gold, sem ramificação em notebooks separados. Dentro de cada bloco, células PySpark (leitura, transformação e escrita dos DataFrames) foram intercaladas com células %sql, usadas para criar/recriar os bancos de dados, validar a qualidade dos dados e materializar as tabelas finais. A função `run_with_retry`, apresentada na seção de carga, foi reaproveitada nas escritas realizadas via PySpark para tornar o notebook mais tolerante a interrupções do cluster.

O banco de dados da camada Silver foi recriado e a tabela de avaliações foi copiada diretamente da camada Bronze:

```
%sql
DROP DATABASE silver CASCADE

%sql
CREATE DATABASE silver

%sql
CREATE TABLE silver.title_ratings AS
SELECT * FROM bronze.title_ratings;
```


	^B _c tconst	^B _c primaryTitle	^B _c titleType	^B _c startYear	^B _c genre
1	tt0000001	Carmencita	short	1894	Docu
2	tt0000001	Carmencita	short	1894	Short
3	tt0000002	Le clown et ses chiens	short	1892	Anim
4	tt0000002	Le clown et ses chiens	short	1892	Short
5	tt0000003	Poor Pierrot	short	1892	Anim
6	tt0000003	Poor Pierrot	short	1892	Come
7	tt0000003	Poor Pierrot	short	1892	Roma
8	tt0000004	Un bon bock	short	1892	Anim
9	tt0000004	Un bon bock	short	1892	Short
10	tt0000005	Blacksmith Scene	short	1893	Short
11	tt0000006	Chinese Opium Den	short	1894	Short
12	tt0000007	Corbett and Courtney Before the Kinetograph	short	1894	Short
13	tt0000007	Corbett and Courtney Before the Kinetograph	short	1894	Sport
14	tt0000008	Edison Kinetoscopic Record of a Sneeze	short	1894	Docu
15	tt0000008	Edison Kinetoscopic Record of a Sneeze	short	1894	Short


 100 rows | 2.085s runtime

Refreshed at 9/26/26, 3:58 PM (7h ago)

Após as etapas de tratamento e validação de qualidade (detalhadas na próxima seção), as tabelas silver.title_ratings e silver.title_basics foram unidas por tconst:

```
%sql
CREATE TABLE silver.title_joined AS
SELECT
  b.tconst,
  b.titleType,
  b.primaryTitle,
  b.startYear,
  b.genre,
  r.averageRating,
  r.numVotes
FROM silver.title_ratings r
LEFT JOIN silver.title_basics b
ON r.tconst = b.tconst;

%sql
SELECT *
FROM silver.title_joined LIMIT 100;
```

	^A _C tconst	^A _C titleType	^A _C primaryTitle	^A _C startYear	^A _C genre	^A _C avg
1	tt0000138	short	The Bewitched Inn	1897	Comedy	6.4
2	tt0000138	short	The Bewitched Inn	1897	Short	6.4
3	tt0000154	short	Henley Regatta	1897	News	3.8
4	tt0000154	short	Henley Regatta	1897	Short	3.8
5	tt0000154	short	Henley Regatta	1897	Sport	3.8
6	tt0000310	short	Chimmie Hicks and the Rum Omelet	1900	Comedy	6.2
7	tt0000310	short	Chimmie Hicks and the Rum Omelet	1900	Short	6.2
8	tt0002844	movie	Fantômas: In the Shadow of the Guillotine	1913	Crime	6.9
9	tt0002844	movie	Fantômas: In the Shadow of the Guillotine	1913	Drama	6.9
10	tt0003584	movie	The \$5, 000, 000 Counterfeiting Plot	1914	Crime	7.0
11	tt0003584	movie	The \$5, 000, 000 Counterfeiting Plot	1914	Thriller	7.0
12	tt0004838	movie	The Wrath of the Gods	1914	Drama	5.8
13	tt0004838	movie	The Wrath of the Gods	1914	Romance	5.8
14	tt0004907	movie	Are You a Mason?	1915	Comedy	7.0
15	tt0005626	movie	The Little Dutch Girl	1915	Drama	6.0



 100 rows 1.586s runtime Refreshed at 9/26/26, 3:58 PM (7h ago)

O banco de dados da camada Gold foi recriado e a tabela final de análise foi construída a partir de silver.title_joined, já filtrada pelos tipos de título de interesse e agregada por ano e gênero:

```

%sql
DROP DATABASE IF EXISTS gold CASCADE;

%sql
CREATE DATABASE gold;

%sql
CREATE TABLE gold.genre_analysis AS
SELECT
  startYear AS year,
  genre,
  AVG(CAST(averageRating AS DOUBLE)) AS avgRating,
  SUM(CAST(numVotes AS INT)) AS totalVotes
FROM
  silver.title_joined
WHERE
  titleType IN ('movie', 'tvShort', 'short', 'tvMovie')
GROUP BY
  startYear,
  genre
ORDER BY
  startYear,
  genre;

```

```
%sql
SELECT *
FROM gold.genre_analysis
WHERE year > 1980 LIMIT 500;
```

	^A _C year	^A _C genre	¹ ₂ avgRating	¹ ₂ ³ totalVotes
1	1981	Action	5.97375	929975
2	1981	Adult	5.563052208835342	16753
3	1981	Adventure	6.13068783068783	2248301
4	1981	Animation	6.570982142857143	214688
5	1981	Biography	6.818987341772153	173374
6	1981	Comedy	5.928535669586984	1047415
7	1981	Crime	6.016605166051661	530137
8	1981	Documentary	6.991349480968858	40160
9	1981	Drama	6.273106323835997	1744757
10	1981	Family	6.493582887700536	46891
11	1981	Fantasy	6.165217391304348	304990
12	1981	History	6.798823529411763	178657
13	1981	Horror	5.5121052631578955	1275060
14	1981	Music	6.860714285714285	46829
15	1981	Musical	6.437974683544304	115198

500 rows 1.590s runtime Refreshed at 9/26/26, 3:58 PM (7h ago)

5. Qualidade de Dados

Ao longo da camada Silver, cada coluna relevante foi verificada quanto à presença de nulos, valores vazios ou fora do domínio esperado, e os problemas identificados foram tratados como descrito a seguir.

Não foram encontrados valores nulos em tconst:

```
%sql
SELECT COUNT(*)
FROM silver.title_basics
WHERE tconst IS NULL;
```

Table

+

	1 ² ₃ COUNT(*)	
1		0

↓

▼

1 row

1.507s runtime

Foram identificadas inconsistências em primaryTitle (nulos, vazios ou marcados como '\N'); optou-se por substituir esses valores por 'Unknown', preservando a linha em vez de descartá-la:

```
%sql
SELECT *
FROM silver.title_basics
WHERE primaryTitle IS NULL OR TRIM(primaryTitle) = '' OR primaryTitle = '\N'
```

Table

+

	A ^B _C tconst	A ^B _C primaryTitle	A ^B _C titleType	A ^B _C startYear	A ^B _C genre
1	tt12279760	N	short	2020	Music
2	tt12279760	N	short	2020	Short
3	tt1321439	N	movie	2005	Documentary
4	tt1403289	N	tvEpisode	2006	Music
5	tt14777874	N	tvEpisode	2021	Family
6	tt19316378	N	tvEpisode	2010	Music
7	tt2381676	N	tvEpisode	1977	Family
8	tt29387614	N	short	2011	Drama
9	tt29387614	N	short	2011	Music
10	tt29387614	N	short	2011	Short
11	tt32915221	N	tvEpisode	2021	Comedy
12	tt32915221	N	tvEpisode	2021	Romance
13	tt3874996	N	tvEpisode	1988	Comedy
14	tt3874996	N	tvEpisode	1988	Family
15	tt3874996	N	tvEpisode	1988	Music

↓

▼

33 rows

2.294s runtime

Refreshed at 9/7/2023 10:00:00 AM

```
%sql
UPDATE silver.title_basics
SET primaryTitle = 'Unknown'
WHERE (primaryTitle IS NULL OR primaryTitle = '\N' OR TRIM(primaryTitle) = '')
```

Table ▾		+
	1 ² ₃ num_affected_rows	
1	33	



 1 row | 5.470s runtime

Não foram encontrados valores nulos em titleType:

```
%sql
SELECT COUNT(*)
FROM silver.title_basics
WHERE titleType IS NULL OR TRIM(titleType) = '' OR primaryTitle = '\N';
```

Table ▾		+
	1 ² ₃ COUNT(*)	
1	0	



 1 row | 2.089s runtime

Como startYear é essencial para a análise, as linhas com esse campo nulo foram removidas da base:

```
%sql
SELECT COUNT(*)
FROM silver.title_basics
WHERE startYear IS NULL OR startyear = '\N';
```

Table ▾ +

	¹ ₃ COUNT(*)
1	2116223

1 row 1.480s runtime

```
%sql
DELETE FROM silver.title_basics
WHERE startYear IS NULL OR startyear = '\N';
```

Table ▾ +

	¹ ₃ num_affected_rows
1	2116223

1 row 3.595s runtime

```
%sql
SELECT COUNT(*)
FROM silver.title_basics
WHERE startYear = '';
```

Table ▾ +


	¹ ₃ COUNT(*)
1	0

1 row 1.590s runtime

Os valores de startYear estavam armazenados como string, sendo necessária a conversão para inteiro a fim de possibilitar comparações e agregações numéricas. Para isso, criou-se a coluna startYear_int:

```
%sql
ALTER TABLE silver.title_basics
ADD COLUMN startYear_int INT;


UPDATE silver.title_basics
SET startYear_int = CAST(startYear AS INT);
```



	num_affected_rows
1	17860738

1 row | 11.207s runtime

```
%sql
SELECT MIN(startYear_int), MAX(startYear_int)
FROM silver.title_basics
```



	MIN(startYear_int)	MAX(startYear_int)
1	1874	2115

1 row | 1.582s runtime

Como o IMDb também cataloga títulos ainda não lançados, optou-se por excluir os registros com startYear igual ou posterior a 2026:

```
%sql
SELECT COUNT(*)
FROM silver.title_basics
WHERE startYear_int > 2025
```

Table ▾ +

	1^2_3 COUNT(*)
1	390826

⬇ ▾

1 row | 2.008s runtime

```
%sql
DELETE FROM silver.title_basics
WHERE startYear_int > 2025;
```

Table ▾ +

	1^2_3 num_affected_rows
1	390826

⬇ ▾

1 row | 3.180s runtime

```
%sql
SELECT COUNT(*)
FROM silver.title_basics
WHERE startYear_int > 2025
```

Table ▾ +


	1^2_3 COUNT(*)
1	0

⬇ ▾

1 row | 1.598s runtime

Como o gênero é uma variável essencial para as análises propostas, os registros sem essa informação foram removidos da base. Uma consulta de distribuição por gênero confirmou volume expressivo de registros em cada categoria remanescente:

```
%sql
SELECT COUNT(*)
FROM silver.title_basics
WHERE genre IS NULL OR genre = '/N' OR TRIM(genre) = '';
```



	COUNT(*)
1	0

1 row 1.584s runtime

```
%sql
SELECT genre, COUNT(*)
FROM silver.title_basics
GROUP BY genre
ORDER BY COUNT(*) DESC
```

	A ^B _C genre	1 ² ₃ COUNT(*)
1	Drama	2927471
2	Comedy	2142248
3	Talk-Show	1343548
4	Short	1283173
5	News	1201586
6	Documentary	1140895
7	Romance	1013083
8	Family	774646
9	Reality-TV	632816
10	Animation	546956
11	Crime	477758
12	Action	476268
13	Adventure	444983
14	Game-Show	443145
15	Music	410660



28 rows | 2.092s runtime

Concluídas as verificações na tabela de títulos, foram realizadas validações equivalentes na tabela de avaliações. Não foram encontrados valores nulos em tconst, averageRating ou numVotes:

```
%sql
SELECT COUNT(*)
FROM silver.title_ratings
WHERE tconst IS NULL OR TRIM(tconst) = '' OR tconst = '\N';
```

Table ▾ +

	1^2_3 COUNT(*)
1	0

⬇ ▾

1 row | 1.292s runtime

```
%sql
SELECT COUNT(*)
FROM silver.title_ratings
WHERE averageRating IS NULL OR TRIM(averageRating) = '';
```

Table ▾ +

	1^2_3 COUNT(*)
1	0

⬇ ▾

1 row | 1.193s runtime

```
%sql
SELECT COUNT (*)
FROM silver.title_ratings
WHERE numVotes IS NULL OR TRIM(numVotes) = '';
```

Table ▾ +

	1^2_3 COUNT(*)
1	0

⬇ ▾

1 row | 1.595s runtime

Também não foram encontradas notas fora do intervalo válido de 0 a 10, nem títulos com zero votos registrados:

```
%sql
SELECT COUNT(*)
FROM silver.title_ratings
WHERE CAST(averageRating AS DOUBLE) < 0 OR CAST(averageRating AS DOUBLE) > 10;
```




Table	
	1 ² ₃ COUNT(*)
1	0

1 row 1.491s runtime

```
%sql
SELECT count(*)
FROM silver.title_ratings
WHERE numVotes = 0;
```




Table	
	1 ² ₃ count(*)
1	0

1 row 1.291s runtime

A correspondência entre as tabelas foi verificada por meio de uma junção (LEFT JOIN) de title_ratings com title_basics, checando a existência de tconst sem correspondente na tabela de títulos:

```
%sql
SELECT COUNT(*)
FROM silver.title_ratings r
LEFT JOIN silver.title_basics b
ON r.tconst = b.tconst
WHERE b.tconst IS NULL;
```

Table ▾		+
	1 ² ₃ COUNT(*)	
1	57031	


 1 row | 3.994s runtime

Por fim, já na camada Gold, os valores de avgRating foram arredondados para três casas decimais, padronizando a apresentação dos resultados:

```
%sql
UPDATE gold.genre_analysis
SET avgRating = ROUND(avgRating, 3);
```

Table ▾		+
	1 ² ₃ num_affected_rows	
1	3115	


 1 row | 2.684s runtime

6. Análise de Dados

Com a tabela gold.genre_analysis consolidada, foram executadas as consultas necessárias para responder às perguntas de negócio definidas na seção 1.

6.1. Ranking de gênero por ano, segundo a média de avaliações

Um recorte para o ano de 1980 mostra os gêneros ordenados pela maior média de avaliação:

```
%sql
SELECT DISTINCT *
```

```
FROM gold.genre_analysis
WHERE year = 1980
ORDER BY avgRating DESC;
```

Table ▼ +				
	^A _C year	^A _C genre	1.2 avgRating	¹ ₂ ³ totalVotes
1	1980	Talk-Show	8	31
2	1980	Documentary	6.928	32047
3	1980	History	6.88	106581
4	1980	Biography	6.783	810262
5	1980	Music	6.71	90969
6	1980	War	6.448	143071
7	1980	Animation	6.436	52673
8	1980	Short	6.411	27798
9	1980	Family	6.402	128965
10	1980	Musical	6.231	70004
11	1980	Drama	6.207	3209049
12	1980	Fantasy	6.197	1669763
13	1980	Romance	6.19	355966
14	1980	Sport	5.997	561314
15	1980	Adventure	5.989	2490485

↓ ▼ 25 rows | 2.275s runtime

O gênero Documentary apresentou a maior avaliação média em 1980, enquanto Horror teve o pior desempenho entre os gêneros considerados. Repetindo a mesma consulta para 1990:

```
%sql
SELECT DISTINCT *
FROM gold.genre_analysis
WHERE year = 1990
ORDER BY avgRating DESC;
```

Table ▼ +				
	^A _C year	^A _C genre	1.2 avgRating	¹ ₃ totalVotes
1	1990	Reality-TV	7.225	232
2	1990	Documentary	6.98	50888
3	1990	Music	6.928	90312
4	1990	Biography	6.565	1713747
5	1990	Musical	6.539	83532
6	1990	History	6.526	79684
7	1990	Animation	6.492	142633
8	1990	Adult	6.396	6815
9	1990	Family	6.35	1021806
10	1990	Short	6.298	26192
11	1990	War	6.237	114713
12	1990	Drama	6.123	6378851
13	1990	Comedy	6.059	4029972
14	1990	Western	6.007	360921
15	1990	Adventure	6.003	2042088

↓ ▼ 24 rows | 1.391s runtime

Dez anos depois, Documentary perde a primeira posição para Reality-TV; esse resultado deve ser interpretado com cautela, pois esse gênero está associado a um número de votos bastante reduzido e, considerando que a tabela final foi construída apenas com títulos classificados como filmes, sua presença pode indicar alguma inconsistência de categorização nos dados de origem. Ainda assim, observa-se crescimento na média de Documentary em relação a 1980, e Horror permanece na última posição, com média ainda menor que a de 1980.

6.2 Combinações de ano/gênero com as maiores notas

A consulta a seguir traz as dez maiores médias de avaliação em toda a série histórica:

```
%sql
SELECT *
FROM gold.genre_analysis
```

```
ORDER BY avgRating DESC
LIMIT 10;
```

Table ▼ +				
	^A _C year	^A _C genre	1.2 avgRating	¹ ₂ ³ totalVotes
1	2015	Game-Show	9.9	10
2	2003	News	8.65	67
3	2025	Game-Show	8.6	108
4	2022	News	8.53	3257
5	2005	Talk-Show	8.5	9
6	1998	Talk-Show	8.5	154
7	1993	News	8.4	30
8	1943	News	8.4	9
9	2002	News	8.15	65
10	2005	Reality-TV	8.15	162

⬇ ▼ 10 rows | 1.191s runtime

Observa-se, no entanto, um padrão recorrente de baixo volume de votos entre essas combinações, o que reduz sua representatividade estatística: notas muito altas calculadas sobre poucos votos são menos confiáveis. Refazendo a mesma ordenação, mas exigindo um mínimo de 50 mil votos, chega-se a um ranking mais robusto:

```
%sql
SELECT *
FROM gold.genre_analysis
WHERE totalVotes > 50000
ORDER BY avgRating DESC
LIMIT 10;
```

Table

+

	A_C^B year	A_C^B genre	1.2 avgRating	1_3^2 totalVotes
1	2008	News	7.9	56286
2	2025	Short	7.568	98518
3	1996	Music	7.441	228788
4	2024	Short	7.349	136419
5	1995	Music	7.307	133580
6	2023	Short	7.277	297603
7	1993	Music	7.265	522880
8	2022	Short	7.257	247201
9	2008	Documentary	7.247	708796
10	1994	Music	7.238	209276

↓

▼

10 rows

1.294s runtime

6.3 Melhores avaliações para um gênero específico

Para o gênero Drama, buscou-se identificar os anos com as maiores médias de avaliação:

```
%sql
SELECT *
FROM gold.genre_analysis
WHERE genre = 'Drama'
ORDER BY avgRating DESC
LIMIT 50;
```

Table

+

	^A _C year	^A _C genre	1.2 avgRating	¹ ₃ totalVotes
1	2025	Drama	6.743	8437291
2	2016	Drama	6.677	21147970
3	2012	Drama	6.661	20406198
4	2017	Drama	6.651	21216041
5	2014	Drama	6.642	24828376
6	2024	Drama	6.611	11655672
7	2011	Drama	6.607	21175222
8	2022	Drama	6.607	16344436
9	2015	Drama	6.597	20839380
10	2010	Drama	6.596	17916183
11	2013	Drama	6.578	22310136
12	2023	Drama	6.572	14991629
13	2018	Drama	6.532	17758767
14	2009	Drama	6.515	17921515
15	2021	Drama	6.501	14676763

↓

▼

50 rows

1.388s runtime

O ano de 1888 aparece entre os mais bem avaliados, mas esse resultado também deve ser interpretado com cautela: está associado a uma quantidade reduzida de votos, o que compromete sua representatividade frente aos demais anos. Para o gênero Action:

```
%sql
SELECT *
FROM gold.genre_analysis
WHERE genre = 'Action'
ORDER BY avgRating DESC
LIMIT 50;
```

Table ▼ +				
	^{A_B} _C year	^{A_B} _C genre	1.2 avgRating	^{1²} ₃ totalVotes
1	2012	Action	6.368	14586398
2	1956	Action	6.301	58534
3	2014	Action	6.256	20971249
4	2013	Action	6.229	17230913
5	1943	Action	6.224	52776
6	2011	Action	6.223	17245074
7	2016	Action	6.219	17197594
8	2025	Action	6.204	7532278
9	1951	Action	6.202	62772
10	1958	Action	6.186	84320
11	2010	Action	6.185	13380200
12	2015	Action	6.177	15773833
13	1957	Action	6.161	86777
14	1945	Action	6.147	22393
15	1948	Action	6.129	89023

↓ ▼ 50 rows | 1.482s runtime

Nota-se uma tendência de avaliações mais elevadas entre os anos mais recentes para esse gênero.

6.4 Anos com maior número de votos

Por fim, identificaram-se os anos que concentram o maior número total de votos, somando todos os gêneros:

```
%sql
SELECT year, SUM(totalVotes) AS total_votes_per_year
FROM gold.genre_analysis
GROUP BY year
```

```
ORDER BY total_votes_per_year DESC
LIMIT 50;
```

Table ▼ +		
	^A _C year	¹ ₃ total_votes_per_year
1	2014	135940920
2	2013	133364998
3	2016	115995226
4	2011	114526798
5	2010	112005085
6	2012	111730254
7	2017	110266739
8	2015	109794132
9	2019	106580090
10	2008	106270824
11	2009	105995010
12	2018	105018674
13	2007	103947850
14	2006	98285734
15	2004	95138461

↓ ▼ 50 rows | 1.289s runtime

Como esperado, dada a popularização da internet e a disseminação de dispositivos eletrônicos, os anos mais recentes concentram maior volume de avaliações. No entanto, o consumo de filmes não se restringe ao período de lançamento: com a consolidação das plataformas de streaming, produções mais antigas continuam sendo assistidas e avaliadas atualmente. Assim, o número de votos reflete tanto a popularidade contemporânea quanto a capacidade de um título permanecer relevante ao longo do tempo.

7. Autoavaliação

De maneira geral, avalio de forma bastante positiva a experiência de desenvolvimento deste trabalho. Antes de iniciar as etapas práticas, defini como objetivo aplicar os conceitos de análise e tratamento de dados aprendidos ao longo da disciplina, construindo um pipeline de dados capaz de transformar informações brutas em conhecimento útil para responder a questões analíticas. Considero que esse objetivo foi alcançado, pois consegui realizar desde a seleção da base de dados até a criação das consultas necessárias para extrair insights relevantes.

Inicialmente, minha intenção era utilizar uma base de dados relacionada a premiações do universo musical, como o Grammy Awards, para analisar características dos álbuns premiados e identificar possíveis padrões entre gêneros musicais. Entretanto, durante a busca por conjuntos de dados no Kaggle, encontrei dificuldades para localizar uma base consistente e adequada aos objetivos propostos. Além disso, surgiram desafios relacionados à qualidade e ao tratamento dos arquivos disponíveis. Diante desse cenário, optei por utilizar a base de dados do IMDb, que apresentava maior volume de informações, melhor estruturação e possibilitava a realização de análises semelhantes às planejadas inicialmente.

Durante a execução do projeto, alguns desafios demandaram decisões importantes sobre o tratamento dos dados. Um dos primeiros foi relacionado à coluna *isAdult*. Inicialmente, considerei corrigir as inconsistências existentes nesse campo; porém, como essa variável não fazia parte do escopo da análise, optei por removê-la. Embora essa decisão tenha simplificado o processo, reconheço que sua exclusão pode limitar futuras análises que eventualmente utilizassem essa informação. Outro ponto de atenção ocorreu quando a chave primária *tconst* perdeu sua unicidade após a etapa de expansão dos gêneros. Avaliei que essa situação era esperada, uma vez que um mesmo título pode estar associado a múltiplos gêneros, e que tal característica não comprometeria os objetivos definidos para o trabalho.

Também enfrentei algumas dificuldades na elaboração de consultas e transformações de dados ao longo do projeto. Em determinados momentos, foi necessário aprofundar meus estudos e consultar materiais de apoio para compreender melhor determinadas operações e implementar as soluções desejadas. Esse processo contribuiu significativamente para o meu aprendizado, pois permitiu consolidar conhecimentos práticos sobre manipulação e análise de dados.

Ao longo das análises, identifiquei limitações que podem ter influenciado alguns resultados obtidos. Uma delas está relacionada à quantidade de avaliações disponíveis para produções mais antigas. Em diversos casos, filmes lançados nos primeiros anos da base apresentavam um número reduzido de votos, o que resultava em médias elevadas, mas pouco representativas do conjunto geral de usuários. Dessa forma, para trabalhos futuros, seria interessante estabelecer critérios mínimos de quantidade de votos ou restringir o período analisado, aumentando a confiabilidade das conclusões obtidas.

Como possibilidade de evolução do projeto, também poderiam ser incorporadas novas variáveis presentes na base do IMDb, como informações sobre profissionais envolvidos nas produções, duração dos títulos ou aspectos relacionados à popularidade. Além disso, seria possível desenvolver visualizações interativas e aplicar técnicas estatísticas mais avançadas para aprofundar a análise dos padrões identificados.

Por fim, considero que a construção do MVP foi uma experiência extremamente enriquecedora. O projeto permitiu colocar em prática os conhecimentos adquiridos ao longo da disciplina e compreender, de forma concreta, todo o processo de transformação de dados brutos em informações relevantes para

a tomada de decisão. Além do desenvolvimento técnico, a atividade proporcionou uma visão mais clara do potencial da análise de dados para gerar conhecimento e apoiar a solução de problemas reais, reforçando meu interesse pela área e ampliando minha compreensão sobre a importância de um processo estruturado de tratamento e análise de dados.